


Les bases de données



```
SELECT empCode, empName  
FROM employee  
SELECT DISTINCT empName  
FROM population  
WHERE Country = "TH"  
empSalary >=  
SELECT AVG(salary)  
FROM salary
```



Qu'est ce qu'une base de données ?


- ▣ Centraliser les données
- ▣ Stocker les données
- ▣ Organiser les données pour faciliter la recherche



Les défis technologiques

Le premier calculateur est né en 1946

- ENIAC : ***Electronic Numerical Integrator And Computer***
- 5k flops
- 167 m²
- 30 Tonnes



1955 : Stockage par bande magnétique




Et votre smartphone ???




Smartphone 2025 :
- Stockage 1To
- 2 Tflops

Première génération de bases de données

- 1965 : Modèle hiérarchique



- 1969 : Modèle Réseau




Connu comme base de données de navigation. On navigue entre les objets par des liens/pointeurs.
[Pas pratique à manipuler.](#)



Seconde génération de bases de données

- 1970 : Le modèle relationnel a fait son apparition avec la publication du Dr Edgar Codd (chercheur IBM)
- Un modèle reposant sur une théorie mathématique : l'algèbre relationnel.
- Les données sont regroupées dans des tables à 2 dimensions avec des lignes et des colonnes.
- Un modèle normalisé afin d'éviter les incohérences de données.



Seconde génération des bases de données

Le modèle relationnel définit la manière d'organiser les données mais ne définit pas la manière dont la base de données gère les accès concurrents.

Le Dr Jim Gray va proposer un modèle transactionnel ou une transaction est définie comme un ensemble de modifications laquelle dispose des propriétés suivantes :

- **Atomicité** : Une transaction est indivisible. Soit toutes les modifications dans la transaction sont appliquées soit aucune.
- **Cohérence** : La base de données reste dans un état cohérent avant et après application d'une transaction.
- **Isolation** : Plusieurs transactions peuvent être traitées simultanément.
- **Durabilité** : Une fois une transaction est appliquée (COMMIT), les changements sont conservés même en cas de panne.



Rappel sur le modèle relationnel

A – Atomicité :

La transaction est tout ou rien : si une opération échoue, la transaction est annulée. Aucune modification partielle ne doit rester.



I – Isolation : Plusieurs transactions peuvent s'exécuter en même temps sans se gêner. Elles doivent se comporter comme si elles étaient traitées l'une après l'autre.

C – Cohérence : Les règles de gestion (contraintes, intégrité...) sont toujours respectées : la base passe d'un état valide/cohérent à un autre état cohérent.

D – Durabilité : Une fois validée (COMMIT), une transaction est définitive : ses modifications ne disparaîtront pas, même en cas de panne.

Seconde génération des bases de données


C'est en combinant le travail du Dr Ed. Codd et celui du Dr Jim Gray qu'une nouvelle ère de bases de données est née.

Les mainframes sont abandonnés au profit de l'architecture client / serveur.


Les SGBDR sont nés : Oracle, IBM, Postgres et bien d'autres.

En 1986, le premier langage de base de données standardisé fait son apparition : le SQL.

Une nouvelle ère de bases de données qui va assister à la naissance du Web 1.0 (1989 - 2004).




L'évolution des bases de données



À mesure que les bases de données grandissent en taille, il devient nécessaire d'investir dans du matériel haute performance pour maintenir des performances optimales. Ce processus est connu sous le nom d'**extensibilité verticale** (scale-up).


L'évolution matérielle

- ❑ A partir des années 2000, le matériel devient accessible à tous.



L'évolution matérielle

Loi de MOORE : Le nombre de transistors sur une puce de silicium double tous les 18 à 24 mois, ce qui entraîne une augmentation exponentielle de la puissance de calcul à coût équivalent.




Troisième génération des bases de données

Le web 1.0 est statique (millions d'utilisateurs) et les attentes des entreprises sur un nouveau marché en ligne (internet) sont fortes.

En 2004, le web 2.0 avec des milliards d'utilisateurs offre la possibilité de réaliser des sites web avec des contenus interactifs imposant une pression forte sur les SGBDR.


Des volumétries astronomiques sont en jeux :



Les applications web passent à l'échelle mais les bases de données relationnelles restent le goulot d'étranglement. L'approche par extensibilité verticale (matériel plus performant) atteint ses limites et coûte cher aux entreprises.

Pour répondre à la charge croissante des applications web, les SGBDR mettent en place des systèmes de replication pour les accès en lecture seulement. Les écritures sont toujours concentrées vers une seule machine.

La problématique des Bases De Données



Vertical Scaling
(Scaling up)

Des bases de données Xtra Large de l'ordre du Péta octet.

Les entreprises expriment des besoins similaires avec l'évolution du web :

- Le Web 1.0 est statique (millions d'utilisateurs) et les attentes des entreprises sur un nouveau marché en ligne (internet) sont fortes.
- Le Web 2.0 avec des milliards d'utilisateurs offre la possibilité de réaliser des sites web avec des contenus interactifs imposant une pression forte sur les SGBDR.

L'approche par extensibilité verticale (matériel plus performant) atteint ses limites et est très coûteuse.




BIG DATA




Les architectures distribuées

- ❑ Une alternative à cette approche est de basculer à une architecture horizontale.
- ❑ « Diviser pour mieux régner »



Vertical Scaling
(Scaling up)




Horizontal Scaling
(Scaling out)

modèle MPP (Massively parallel processing)
où
shared nothing.

***What
the
.....?***



Le NoSQL



Le NoSQL


- Les bases de données Not Only SQL (NOSQL)




BDD Orientée Colonne



BDD Orientée Document






BDD Orientée Graph




BDD Orientée Clé-valeur

- On privilégie la performance et l'extensibilité horizontale.



La tendance BIG DATA



Osman AIDEL

Les bases de données vectorielles

Une base de données vectorielle est une base de données spécialement conçue pour stocker, indexer et rechercher efficacement des vecteurs, généralement composés d'un grand nombre de dimensions.

Mais pourquoi représenter des données sous forme de vecteurs ?

Des objets tels que des textes, documents, images, sons ou vidéos peuvent être transformés par un modèle en une représentation numérique appelée embedding.

Un embedding représente un objet par un vecteur dans un espace à N dimensions, de manière à capturer certaines de ses caractéristiques ou propriétés sémantiques.

Dans cet espace, plus les vecteurs sont proches, plus les objets qu'ils représentent sont considérés comme similaires, selon la représentation apprise par le modèle.

Ainsi, plutôt que de rechercher uniquement une correspondance exacte sur des mots, il devient possible de rechercher des objets sémantiquement similaires.

C'est ce principe qui permet notamment de réaliser de la recherche sémantique, de rechercher des images similaires, de construire des systèmes de recommandation ou encore d'alimenter des architectures RAG (Retrieval-Augmented Generation) utilisées avec les LLM.

1

Données à stocker

Différents types de contenus

**Textes**

(articles, documents, FAQ, ...)

**Images**

(photos, schémas, ...)

**Sons**

(chansons, enregistrements, ...)

**Vidéos**

(films, tutoriels, ...)

2

Génération des embeddings

Un modèle transforme chaque contenu en un vecteur numérique

**Modèle d'IA**

(ex : modèle d'embedding)

[0.12, -0.45, 0.81, ...]

[0.03, 0.67, -0.21, ...]

[-0.31, 0.22, 0.44, ...]

[0.55, -0.18, 0.09, ...]

⋮

3

Stockage dans une base vectorielle

Les embeddings sont stockés et indexés pour permettre une recherche efficace

**Base de données vectorielle**

[0.12, -0.45, 0.81, ...]



[0.03, 0.67, -0.21, ...]



[-0.31, 0.22, 0.44, ...]



[0.55, -0.18, 0.09, ...]

⋮

4

Recherche vectorielle

On transforme la requête en vecteur et on recherche les vecteurs les plus proches

Requête utilisateur


« voiture électrique »

**Modèle d'IA**

(même modèle d'embedding)

Vecteur de la requête

[0.28, -0.31, 0.76, ...]

Recherche
des plus proches voisins
(similarité vectorielle)**Espace vectoriel** (exemple en 2D pour la visualisation)**Résultats**

Les objets les plus proches sont renvoyés

**Voiture électrique : guide complet**

Découvrez les avantages des véhicules électriques ...

Score : 0,92

**Véhicule à batterie : comment ça fonctionne ?**

Un véhicule à batterie utilise ...

Score : 0,87


**Comparatif des voitures électriques en 2024**

Tesla, Renault, Hyundai ...


Score : 0,83

...

En résumé




Aujourd'hui (415 DB)




Vision des bases de données en 2012

The evolving database landscape



© 2012 by The 451 Group. All rights reserved

Vision des plateformes de données en 2016



Comment puis-je vous aider ?

Poser une question

+ Joindre

 Rechercher

 Raisonner

 Voix

